

Lending Club 데이터를 활용한 포트폴리오 Sharpe Ratio 극대화 모델링 연구

6조 (권서영 이소민 이유림 조성우 지희선 홍예나)

1. 서론.....	2
1.1. 연구 목적.....	2
1.2. 기대효과.....	2
2. 본론.....	3
2.1. 연구 방법.....	3
2.1.1. 개괄적 소개.....	3
2.1.2. 핵심 개념 설명.....	4
2.2. 데이터 탐색적 분석(EDA) 및 전처리.....	6
2.3. 모델링.....	11
2.3.1. Naive Bayes.....	11
2.3.2. Support Vector Machine.....	13
2.3.3. Random Forest.....	14
2.3.4. LightGBM.....	15
2.3.5. XGBoost.....	16
2.3.6. Multi Layer Perceptron.....	18
3. 결론.....	19
3.1. 모델 성능 비교.....	19
3.2. 결과 논의 및 시사점.....	20
3.3. 한계점과 향후 과제.....	23
3.3.1. Sharpe Ratio의 절대적 수준 개선.....	23
3.3.2. Sharpe Ratio를 학습 목적함수로의 직접 설정.....	24
4. 참고문헌.....	24

1. 서론

1.1. 연구 목적

Lending Club(이하 LC)은 개인 간 대출을 중개하고 대출자와 투자자 양쪽에서 수수료를 받는 P2P(peer-to-peer) 대출 플랫폼이다. LC은 대출 신청자의 신용 위험을 평가함으로써 투자자가 개인에게 직접 대출을 제공하거나 여러 대출에 돈을 분산 투자할 수 있도록 한다. 대출 성사 시 LC은 대출자로부터 1%~5%의 발급 수수료를, 투자자로부터 상환 금액의 1%를 서비스 수수료로 받는다.

LC은 전통적인 중개기관인 은행보다 운영비용이 낮기 때문에 대출자는 낮은 금리로 자금을 빠르게 조달할 수 있다. 또한 투자자는 예금, 채권에 비해 상대적으로 높은 수익률을 기대할 수 있다고 포트폴리오를 다변화할 수 있다는 장점이 있다. 이와 같은 구조 하에 LC에 대한 투자는 플랫폼에 대한 신뢰에 기반하므로 대출자의 부도 위험으로 인한 투자자의 손실 빈도가 잦으면 플랫폼의 지속 가능성이 떨어진다.

따라서 LC은 대출자의 부도 위험을 정확하게 파악할 유인이 있다. 이에 기존 연구의 목적은 일반적으로 머신러닝을 통해 LC 대출자의 부도 위험을 파악하는 것이다. 이를 위해서는 부도 예측 정확도를 나타내는 F1 score와 전반적인 부도 위험을 구분하는 AUC 지표는 활용할 수 있다.

다만 대출자의 부도 위험을 파악하는 궁극적 이유는 위험 대비 수익을 최대화하기 위함이다. 위험 대비 투자 성과 극대화라는 궁극적 목적을 위해서는 단순히 정확한 부도 예측이 아닌 개별 대출이 미국 국채 수익률과 비교해 초과수익이 얼마나 되는지를 계산하여야 한다. 이에 본 연구에서는 전통적인 분류 지표 대신 Sharpe Ratio를 성과 평가의 핵심 지표로 선정했다. 또한 대출별 IRR(내부수익률)을 산출하고 이를 동일 만기의 미국 국채 수익률과 비교하여 초과수익 여부를 레이블(y)로 정의했다.

1.2. 기대효과

먼저 본 연구는 기존 신용 평가의 한계점 극복을 위해 Sharpe Ratio를 새로운 모델 평가 기준을 제시했다는 데에 의의가 있다. 전통적인 중개기관과 달리 그간 온라인 금융 플랫폼은 FICO 점수 등을 이용한 단순한 정량적인 신용 점수 시스템을 활용해왔다. 이러한 방식은 다양한 변수간

관계를 정확히 포착하지 못한다. 부도 위험을 예측하는 전통적인 성능 평가 지표인 F1 score와 AUC는 LC 플랫폼 전반의 궁극적 목적인 수익 극대화에 적합하지 않다.

이에 반해 본 연구에서는 Sharpe Ratio 향상을 위해 미국 국채 수익률과 비교하여 초과수익 여부를 레이블(y)로 정의하면서 LC 플랫폼의 궁극적 목적인 수익 극대화에 더 잘 부합할 것으로 기대된다. 거시적으로는 LC의 안정성과 수익성을 높이면서 P2P 플랫폼 생태계 유지에 기여할 것으로도 예상된다.

2. 본론

2.1. 연구 방법


이 연구에서는 개인대출의 상환 결과(완납, 부도, 부실 처리 등)에 기반하여 투자 성과를 Sharpe Ratio 관점에서 최적화하는 분류 문제로 접근했다. 일반적으로 분류 모델은 단순히 학습 데이터의 정답(y)을 잘 맞추는 데 초점을 두지만 해당 연구는 투자자의 관점에서 위험 대비 수익 효율성을 극대화하는 것을 목표로 했다. 따라서 단순 정확도 향상이 아니라 포트폴리오의 Sharpe Ratio가 최종적으로 최대화되도록 학습 전략과 레이블 정의를 재구성했다.

2.1.1. 개괄적 소개

초기에는 모델 설계 방향을 대출 상환 여부($y=0$ 부도, $y=1$ 정상 상환)를 그대로 예측하는 전통적 분류 문제로 설정했다. 그러나 이러한 방법은 Sharpe Ratio 최적화 목적과 직접 연결되지 않는다. 예를 들어, 단순히 ‘정상 상환 여부’를 맞히는 것보다 투자 수익률(IRR)이 국채 수익률보다 낮아 포트폴리오에 포함할 경우 전체 Sharpe Ratio를 악화시키는 대출을 식별하는 것이 실제 목표에 더 적합하다고 판단했다.

이에 따라 y 레이블을 재정의했다. 즉, 대출 IRR이 국채 수익률보다 작은 경우를 $y=1$ (제외해야 할 대출), 반대로 국채 수익률보다 큰 경우를 $y=0$ (포트폴리오에 포함 가능)으로 설정했다. 이는 Sharpe Ratio 극대화라는 최종 목적을 달성하기 위해 투자자가 선택해서는 안 되는 대출을 분류하는 문제로 문제 구조를 재설계한 것이다.

단순한 대출 상환 여부가 아니라 실제 현금흐름에서 도출된 IRR 기준으로 투자 성과에 미치는 영향을 반영하기 위해 y 를 재정의했다. 대출 IRR의 분포를 확인한 결과 국채 대비 IRR이 낮은 대출은 음수 수익률이 많고 변동성이 커 포트폴리오 Sharpe Ratio를 저해하는 경우가 많았다. 따라서 초과 수익 달성 여부를 정확히 식별하는 것이 모델의 핵심 목표이며 이는 결과적으로 Sharpe Ratio를 최대화하는 투자 전략과 같은 맥락을 공유한다.



〈figure 1. 대출 IRR의 분포〉

2.1.2. 핵심 개념 설명

- NPV

순현재가치(Net Present Value, NPV)는 투자안의 경제적 타당성을 평가하는 지표로 미래 현금흐름을 현재 가치로 환산하여 합산한 값이다. 수식은 각 시점의 현금흐름($cash_flow_t$)을 할인율(r)로 조정하여 현재가치로 만든 후 전체 기간(T) 동안 합산하는 방식이다.

초기 투자비용은 보통 음수의 현금흐름으로 시작하며 이후에는 매출이나 비용 절감 등이 반영된다. 할인율은 자본비용이나 요구수익률을 나타내며 할인율이 높을수록 미래 현금흐름의 현재 가치는 줄어든다. 시간(t)은 화폐의 시간가치를 반영하므로 할인계수 $(1 + r)^t$ 가 증가함에 따라 미래 흐름은 감소한다.

- IRR

$$Net\ Present\ Value(NPV) = \sum_{t=0}^T \frac{cash_flow_t}{(1+r)^t}$$

이때, $\sum_{t=0}^T \frac{cash_flow_t}{(1+r)^t} = 0$ 을 만족하는 r 이 IRR이다. 여기서 cash_flow는 시점 t 의 현금 흐름을 의미하며 아래와 같이 원리금 균등 상환으로 가정하여 계산한다.

$$cash_flow = [-loan_amnt] + [total_pymnt/real_term] \times real_term$$

real_term은 실제 대출발행시점(issue_d)와 last_pymnt_d(마지막 상환 시점)을 비교해서 실제로 상환에 걸린 시간이다. 다만 real_term이 실제 약정 상환 기간(term)보다 긴 경우, 즉 연체나 부도가 발생했을 시에는 term으로 계산한다.

대출 데이터에서는 매달 납입되는 원리금 상환액을 기준으로 월간 IRR을 구하고 다음 공식을 활용해 연간 기준으로 변환했다.

$$Annual\ IRR = (1 + Monthly\ IRR)^{12} - 1$$

대출 건별 실제 현금 흐름을 반영하여 연간 내부수익률을 계산한 것이다. 현금 흐름은 처음에 발생한 대출금(음수 값)과 매월 상환액으로 구성되며 전체 상환기간 동안의 흐름을 합산해 IRR을 추정한다.

이후 분석에서는 이같이 계산된 개별 대출의 연간 IRR과 해당 시점의 미국 국채 연간 IRR을 비교했다. 대출 IRR이 국채 IRR보다 높아 투자 수익률이 더 크다면 투자 수익률이 좋은 대출 건이라고 판단하여 레이블 $y=0$ 으로 설정하고 반대의 경우에는 $y=1$ 으로 설정했다.

- Sharpe Ratio

Sharpe Ratio는 투자 성과를 평가할 때 널리 사용되는 지표로 초과수익률의 기대값을 변동성(표준편차)으로 나눈 값이다. 동일한 위험 수준에서 얼마나 효율적으로 수익을 창출했는지를 나타내는 척도이다.

$$Sharpe\ Ratio = \frac{E[Excess\ return]}{\sigma(Excess\ return)}$$

위의 수식의 분자는 투자 초과수익률의 평균을, 분모는 초과수익률의 변동성을 의미한다. 따라서 Sharpe Ratio가 높다는 것은 동일한 위험 대비 더 많은 수익을 거뒀음을 뜻하며 반대로 낮을 경우 위험 대비 효율이 떨어짐을 의미한다.


2.2. 데이터 탐색적 분석(EDA) 및 전처리

이 연구에서는 파이썬의 결측치 분석 라이브러리인 missingno를 활용하여 데이터의 결측치 분석을 진행했다. 먼저 설명변수들의 결측치 개수를 살펴본 결과, 일부 열들에서 결측치 개수가 동일함을 알 수 있었다. 또한, 'mths_since_last_delinq', 'mths_since_last_record', 'open_acc_6m', 'open_act_il', 'open_il_24m', 'mths_since_rcnt_il', 'total_bal_il', 'il_util', 'open_rv_24m', 'max_bal_bc', 'all_util', 'inq_fi', 'total_cu_tl', 'inq_last_12m', 'mths_since_recent_bc_dlq', 'mths_since_recent_revol_delinq' 설명변수들은 결측 비율이 40% 이상임을 확인했다.




<figure 2. 설명변수 결측치 개수 bar plot>

또한 결측치 패턴을 기반으로 계층적 클러스터링과 상관관계를 분석한 결과 특정 변수들에서 결측치가 동시에 발생한다는 것을 발견했다. 이를 통해 결측치가 무작위로 발생한 것이 아니라 구조적인 요인에 의해 발생했을 가능성이 높다고 추정했다.



〈figure 3. 결측패턴 상관관계〉



〈figure 4. 결측패턴 dendrogram〉

위 분석을 바탕으로 본 연구팀은 다음과 같은 결론을 내렸다.

- 결측치 비율이 40% 이상인 열을 보간(imputation)할 경우 오히려 imputation error가 증가할 가능성이 크다.
- 결측치 비율이 40% 이하인 열은 보간이 가능하나 결측 패턴이 유사한 변수들끼리 보간을 진행할 경우 bias가 증가할 수 있다.


이러한 문제를 해결하기 위해 본 연구에서는 사이킷런의 IterativeImputer를 확장하여 CustomIterativeImputer를 설계했다. 주요 파라미터는 다음과 같다.

- exclude_cols: 결측치 비율이 높아 보간에서 제외할 열을 지정하며 이 열들은 보간 후 최종 데이터프레임에서도 제거된다.
- estimator: 보간 시 사용할 추정기를 설정하며 기본값은 BayesianRidge이나 RandomForestRegressor 등 다른 회귀 모델도 가능하다.
- max_iter: IterativeImputer의 반복 횟수를 의미한다.
- tol: 수렴 조건을 설정하여 이전 반복 대비 변화가 특정 값보다 작으면 조기 종료한다.
- n_nearest_features: 보간 시 predictor로 활용할 변수 개수를 제한한다.
- initial_strategy: 최초 결측치 대체 방식을 지정하며, 평균(mean), 중앙값(median), 최빈값(most_frequent), 상수(constant) 중 선택할 수 있다.
- imputation_order: 보간 순서를 결정하며 결측치가 적은 열부터 채우는 “ascending”, 많은 열부터 채우는 “descending”, 무작위 “random” 등이 가능하다.
- skip_complete: 결측치가 없는 열을 학습 과정에서 건너뛰지 여부를 설정한다.
- min_value, max_value: 보간된 값의 하한과 상한을 지정하며, 렌딩클럽 데이터의 특성을 고려해 하한을 0으로 설정했다.
- random_state: 난수 시드를 고정하여 결과의 재현성을 확보한다.

- `na_corr_thresh` (Custom parameter): 본 연구에서 추가한 핵심 파라미터로, 결측 패턴 상관계수가 특정 Threshold(예: 0.5) 이상인 열들을 predictor에서 제외하여 보간 시 편향 발생을 줄이고자 했다.

종합하면 해당 연구의 결측치 분석 및 전처리 과정은 단순한 결측치 보완을 넘어 결측치의 구조적 특성을 반영한 맞춤형 보간 방법론을 도입해 데이터 품질을 개선하는 데 중점을 뒀다.

- 수치형 변수 스케일링



〈figure 5, 6. 스케일링 전후〉

수치형 변수는 quantile transformation을 이용해 스케일링과 분포 안정화를 시도했다.

- 범주형 변수 인코딩

범주형 변수는 최대한 차원이 늘어나는 것을 방지하는 방식으로 인코딩을 진행했다.

예를 들어 `emp_length`(근속기간) 변수는 순서가 있는 범주형 변수이므로 ordinal encoding을 사용했다. NA 값은 0으로 처리하고, < 1 year는 1, 1 year는 2, 2 years는 3과 같이 순서를 반영해 숫자로 변환했다. 이같은 방식을 활용하면 근속기간이 길수록 값이 커지도록 하여 변수의 순서를 보존할 수 있다.

반면 `home_ownership`(주택 소유 여부) 변수는 순서가 없는 범주형 변수이므로 one-hot encoding을 적용했다. 다만 원본 데이터에는 MORTGAGE, RENT, OWN 외에도 ANY, OTHER, NONE과 같은 소수의 범주가 존재했는데 이들은 데이터 수가 적고 분석적 의미가

제한적이므로 하나로 합쳐 처리했다. 최종적으로는 MORTGAGE, OWN, RENT 세 가지 주요 범주에 대해 one-hot 인코딩을 진행하여 불필요한 차원 증가를 방지했다.

Purpose 변수는 본래 다양한 카테고리 구성되어 있었으나 의미적으로 유사한 항목들을 묶어 4개의 그룹으로 재범주화했다. 예를 들어 debt_consolidation과 credit_card는 finance 그룹으로, vacation, wedding, medical, educational 등은 life 그룹으로 통합했다. 또한 home_improvement, car, major_purchase 등은 large expense로 묶었고 나머지 소수 범주들은 other로 처리했다. 이 과정에서 other 그룹은 제외하고, 주요 세 가지 그룹에 대해서만 one-hot encoding을 적용하여 불필요한 차원 증가를 방지했다.

verification_status(대출 신청자의 소득 검증 상태) 변수는 verified와 source verified를 하나로 합쳐 단순화했다. 이후 결측치와 not verified는 0으로, verified 계열은 1로 변환하여 binary encoding을 적용했다.

마찬가지로 initial_list_status 변수는 단순히 w와 f 두 값만 존재하므로 각각 1과 0으로 변환해 binary encoding을 진행했다.

위 과정은 데이터 정보를 보존하면서도 데이터가 효율적으로 모델 학습에 활용될 수 있도록 설계한 과정이다. 이에 따라 복잡하고 다양한 범주형 변수들이 차원 증가 없이 모델에 투입될 수 있도록 단순화되었으며 최종적으로는 10개의 범주형 변수 열이 생성되었다.

- 기타 전처리: 불필요 변수 제거 및 최종 파이프라인 구축

먼저 변수 revol_util(신용카드 사용률, %)은 수치형임에도 원본데이터에 '%'가 붙은 문자형으로 되어 있어 %을 제거하고 수치형으로 변환했다. 이어 fico_range_high와 fico_range_low 두 변수는 서로 강한 상관관계를 갖고 있었기 때문에 중복 정보를 줄이기 위해 평균값을 취한 avg_fico라는 새로운 변수로 통합했다.

이러한 과정을 거쳐 최종 전처리 파이프라인이 완성됐다. 파이프라인은 크게 두 단계로 나눌 수 있다.

1. 공통 전처리(pre_common) 단계에서는 RevolUtilCleaner, FicoAverager, ColumnDropper 모듈을 통해 불필요한 열을 제거하고, FICO 점수의 평균 값인 avg_fico 열을 생성한다.

2. 특성 처리(features) 단계에서는 범주형 변수와 수치형 변수를 각각 인코딩 및 변환한다. 범주형 변수(term, emp_length, home, purpose, verification_status, initial_list_status)는 각 변수의 특성에 맞는 인코더로 변환되며, 수치형 변수(num)는 CustomIterativeImputer를 활용해 결측치를 대체한 뒤 QTWrapper를 통해 정규화 또는 변환 과정을 거친다.


결과적으로 이 파이프라인은 불필요한 변수를 정리하고 결측치와 범주형 변수를 적절히 처리하여 모델이 효율적으로 학습할 수 있는 데이터셋을 생성하는 역할을 한다. 즉, 단순한 데이터 정리 단계를 넘어 모델링 성능을 높이기 위한 전략적 전처리 과정이라고 할 수 있다.

2.3. 모델링

2.3.1. Naive Bayes

Naive Bayes(NB)는 베이즈 정리를 기반으로 한 확률적 분류 알고리즘이다. NB는 class가 조건부로 주어졌을 때 변수들간 독립성을 가정한다.

이 알고리즘은 입력된 데이터가 특정 클래스에 속할 확률(Posterior probability)을 계산하고 그중 가장 확률이 높은 클래스를 예측값으로 선택한다. 수학적으로는 베이즈 정리를 활용하여 posterior probability를 구하며 변수들 간 조건부 독립이라고 가정함으로써 복잡한 조건부 확률 계산을 단순화한다.



Mean Sharpe: 0.1424
Optimal Threshold: 0.1647
Std Sharpe: 0.0006
Best Sharpe: 0.1439

이번 분석에서는 부트스트랩 기법을 활용하여 Sharpe Ratio와 최적 Threshold의 분포를 검증했다.

부트스트랩을 활용한 성과 분석 결과 평균 Sharpe Ratio는 0.1424로 나타났으며 표준편차는 0.0006으로 매우 작은 값을 보였다. 이는 데이터 샘플링에 따른 변동성이 거의 없음을 의미하며 전략의 안정성이 높다는 점을 시사한다. 또한 가장 높은 Sharpe Ratio는 0.1439로, 평균값과 큰 차이가 없다는 점에서 특정 표본에 의존하지 않고 일관된 성과를 내고 있음을 확인했다.


모든 실험에서 최적 Threshold의 분포는 거의 동일하게 0.165 근처에 수렴했다. 평균 Threshold는 0.1647로 계산됐고 분포가 단일 지점에 집중되어 있다는 점은 모델이 투자 의사결정 기준을 매우 안정적으로 제시한다는 의미이다.

2.3.2. Support Vector Machine

SVM(Support Vector Machine)은 주어진 데이터를 가장 잘 분리하는 hyperplane을 찾아내는 지도학습 분류 알고리즘이다. 두 개의 클래스를 나누는 여러 개의 결정 경계 중에서, 클래스 간의 마진을 최대화하는 hyperplane을 찾는다.

SVM에서 가장 중요한 개념은 Support Vector이다. 이는 결정 경계와 가장 가까이 위치한 데이터 포인트(마진)들을 의미한다. 이 점들이 결국 초평면을 결정하는 핵심 역할을 하며 모델 전체를 대표한다고 볼 수 있다. 이러한 특성 때문에 SVM은 노이즈가 많은 데이터보다는 분류 경계가 명확한 데이터에서 더 강력한 성능을 발휘한다.

또한 SVM은 Kernel Trick을 활용하여 비선형 문제에도 대응할 수 있다. 선형적으로 분리가 불가능한 데이터라도 커널을 통해 고차원 공간으로 mapping하면 선형 분리가 가능하다.



Mean Sharpe: 0.0815

Optimal Threshold: 0.2473

Std Sharpe: 0.0004

Best Sharpe: 0.0830

rbf 커널을 사용한 SVM 모델을 학습시킨 후 Sharpe Ratio의 분포를 살펴본 결과 평균은 0.0815로 나타났으며 표준편차는 0.0004로 매우 작은 수준을 보였다. 이는 모델의 성과가 전반적으로 낮은 수준에 머물러 있음을 보여주며 동시에 부트스트랩 샘플링에 따른 성과 변동성이 크지 않음을 의미한다. 분포는 대체로 0.0812 ~ 0.0830 구간에 집중되어 있었으며 최고 Sharpe Ratio는 0.0830으로 평균 대비 소폭 높은 수치를 기록했다. 이러한 결과는 모델이 수익 대비 위험 관리 측면에서 안정적인 추정을 제공하고 있으나 절대적인 성과 수준은 제한적임을 시사한다.

한편, 최적 Threshold의 분포에서는 평균이 0.2473으로 나타났으며 대부분의 값이 0.20~0.25 구간에 집중됐다. 다만 일부 샘플에서는 0.3 이상까지 산발적으로 분포하는 양상이 관측됐다. 이는 Threshold가 특정 구간으로 모이는 경향성을 보이면서도 데이터의 특성에 따라 일정 수준의 변동성이 존재한다는 것을 의미한다.


2.3.3. Random Forest

Random Forest는 Bagging(Bootstrap Aggregating) 기법을 활용한 앙상블 학습 알고리즘으로 여러 개의 결정 트리를 무작위로 학습시킨 뒤 그 결과를 종합하여 최종 예측을 수행하는 모델이다.

Random Forest에서는 각 트리를 학습할 때 bootstrap sampling을 통해 원본 데이터에서 무작위로 표본을 뽑아 사용한다. 또한 트리의 각 split 과정에서도 전체 feature 중 일부만 무작위로 선택하여 고려한다. 이렇게 두 가지 무작위성을 도입함으로써 개별 트리들이 서로 다른 관점을 학습하게 되고 그 결과 overfitting을 방지하면서 일반화 성능을 크게 향상시킬 수 있다.

예측 단계에서는 회귀의 경우 여러 트리의 예측값을 평균내고, 분류의 경우 다수결 투표를 통해 최종 결과를 결정한다. 이러한 방식은 단일 결정트리에 비해 변동성을 줄이고 안정적인 성능을 보장하는 효과가 있다.

Random Forest는 특성 중요도를 계산할 수 있어 변수 선택이나 데이터 해석 과정에서 유용하다.



Mean Sharpe: 0.1835

Optimal Threshold: 0.1647

Std Sharpe: 0.0006


Best Sharpe: 0.1844

Sharpe Ratio의 분포를 살펴본 결과 평균값은 0.1835로 나타났으며 분포 범위는 대체로 0.1825에서 0.1845 사이에 집중되어 있었다. 표준편차는 0.0006으로 매우 작은 수준에 불과하여 샘플링에 따른 성과 변동성이 낮고 지수 추정의 안정성이 높음을 확인할 수 있었다. 또한 최고 Sharpe Ratio는 0.1844로 평균 대비 소폭 높은 수치를 기록했으나 전반적으로 분포가 밀집되어 있어 모델의 성능이 일관적으로 유지된다는 점을 의미한다.

최적 Threshold의 분포를 살펴본 결과, 평균은 0.1647로 나타났으며 대부분의 샘플이 0.165 근처에 집중되어 있었다. 이는 모델의 의사결정 기준이 특정 값으로 명확히 수렴하고 있으며, 샘플링 방법이나 데이터의 변동성에도 크게 영향을 받지 않는다는 점을 보여준다.

2.3.4. LightGBM

LightGBM(Light Gradient Boosting Machine)은 Gradient Boosting 프레임워크로, 대용량 데이터와 고차원 특징에 최적화된 머신러닝 알고리즘이다. LightGBM의 가장 큰 특징은 histogram 기반의 학습 방식과 leaf-wise 트리 성장 전략이다. 일반적인 트리 학습은 데이터를 전부 정렬하여 분할점을 찾는데 LightGBM은 데이터를 구간으로 나누어 처리함으로써 속도와 메모리 사용량을 크게 줄인다. 또한 Depth-wise 방식 대신 Leaf-wise 방식을 채택하여 손실 감소를 가장 크게 만드는 방향으로 트리를 성장시킨다. 이로 인해 더 적은 트리로도 높은 정확도를 달성할 수 있다.



Mean Sharpe: 0.1990
Optimal Threshold: 0.4226
Std Sharpe: 0.0009
Best Sharpe: 0.2009

LightGBM 모델을 활용한 실험 결과, 부트스트랩을 통해 반복적으로 계산된 Sharpe Ratio는 평균 0.1990으로 나타났으며 표준편차는 0.0009로 매우 작았다. 이는 LightGBM 기반 전략의


성과가 재표본추출 상황에서도 흔들림이 거의 없음을 의미하며, 모델이 상당히 안정적인 성과를 제공한다는 점을 보여준다. 또한 가장 높은 Sharpe Ratio는 0.2009로 관측되었는데 평균값과의 차이가 크지 않아 극단적인 경우에도 전략이 일관성을 유지한다는 사실을 확인할 수 있다.

한편 최적 Threshold의 분포는 모든 실험에서 거의 동일하게 0.42 부근에 집중됐다. 평균 Threshold는 0.4226으로 계산됐으며 분포가 단일 값에 수렴하는 특성을 보였다. LightGBM은 다른 기법과 비교했을 때 Sharpe Ratio의 안정성이 매우 뛰어나며 최적 Threshold 또한 일관되게 도출된다는 장점이 있다.

2.3.5. XGBoost

XGBoost(Extreme Gradient Boosting)는 LightGBM과 마찬가지로 Gradient Boosting 알고리즘을 최적화하여 속도와 성능을 모두 개선한 모델이다. Leaf-wise로 손실함수가 낮아지는 노드에서 분기가 일어나는 LightGBM과 달리 XGBoost는 기본적으로 Depth-wise로 분기하여 더욱 안정적인 분기를 수행한다.

특히 XGBoost는 L1, L2 정규화 항을 손실 함수에 포함시켜 모델의 복잡도를 제어함으로써 과적합이 일어날 가능성이 LightGBM에 비해 낮으며 뛰어난 일반화 성능을 보여준다. 또한 누락값(missing value)에 대해서도 내재된 처리 로직을 가지고 있어 실제 데이터 환경에서 안정적으로 활용될 수 있다.



Mean Sharpe: 0.2002
Optimal Threshold: 0.3195
Std Sharpe: 0.0006
Best Sharpe: 0.2016

XGBoost 모델을 적용한 결과 부트스트랩 기반으로 계산된 Sharpe Ratio는 평균 0.2002로 나타났으며 표준편차는 0.0006에 불과했다. 이는 XGBoost가 재표본추출 과정에서도 안정적인 성과를 유지한다는 점을 보여주며 모델이 잡음에 강하고 일관성 있는 결과를 산출함을 의미한다. 또한 가장 높은 Sharpe Ratio는 0.2016로 평균값과 큰 차이가 나지 않아 성과가 특정 표본에 치우치지 않고 균일하게 유지된다는 특징을 확인할 수 있었다.

최적 Threshold의 분포는 대부분 0.3195 부근에서 수렴했다. 전반적으로 동일한 값 근처에 집중되는 패턴을 보여 전략 적용 시 의사결정 기준을 명확하게 제시해 준다.

종합적으로, XGBoost 모델은 LightGBM과 마찬가지로 매우 안정적인 Sharpe Ratio를 확보하며 최적 Threshold 역시 뚜렷하게 특정 구간에 수렴하는 특징을 보였다.


2.3.6. Multi Layer Perceptron

MLP (Multi-Layer Perceptron)는 인공신경망(Artificial Neural Network)의 가장 기본적인 형태로 입력층(input layer), 하나 이상의 은닉층(hidden layer), 그리고 출력층(output layer)로 구성된다. 퍼셉트론이 단일 선형 분류기라면, 다층 퍼셉트론은 여러 개의 층을 쌓아 올려 비선형적인 문제까지 학습할 수 있는 구조를 갖춘 모델이다.

MLP의 핵심은 각 층을 이루는 뉴런들이 가중치와 편향으로 통해 입력 신호를 선형 결합한 뒤 활성화 함수를 적용한다는 점이다. 활성화 함수로는 전통적으로 sigmoid나 tanh가 사용되었지만 최근에는 학습 효율이 높은 ReLU 계열 함수가 널리 쓰이고 있다. 이러한 활성화 함수 덕분에 MLP는 단순한 선형 모델을 넘어선 비선형 함수 근사 능력을 갖게 된다.

학습 과정에서는 Backpropagation 알고리즘과 Gradient Descent을 사용하여 가중치와 편향을 최적화한다. 입력 데이터가 네트워크를 통과하면서 출력값을 생성하고 이 출력값과 실제 정답 사이의 오차를 손실 함수(loss function)로 계산한다. 그 후 오차를 출력층에서부터 입력층으로

거꾸로 전파하면서 각 연결 가중치가 얼마나 기여했는지를 계산하고 이를 바탕으로 가중치를 업데이트한다.



Mean Sharpe: 0.1889

Optimal Threshold: 0.1493

Std Sharpe: 0.0026

Best Sharpe: 0.1940

부트스트랩 기법을 통해 반복적으로 Sharpe Ratio를 계산한 결과 전반적으로 안정적인 성과가 확인됐다. Sharpe Ratio의 평균값은 0.1889로 나타났으며, 표준편차는 0.0026에 불과해 대표본추출에 따른 변동성이 크지 않았다. 이는 전략이 데이터의 변화에도 비교적 일관된 성과를 낼 수 있음을 보여준다. 또한 가장 높은 Sharpe Ratio는 0.1940으로 평균값과 큰 차이가 나지 않아 전략의 성과가 특정 표본에 과도하게 의존하지 않는다는 점을 시사한다.

한편, 최적 Threshold의 분포를 살펴보면 대체로 0.12와 0.16 근처에 집중되어 있으며, 평균값은 약 0.1493으로 나타났다. 이는 전략을 실제로 적용할 때 투자 여부를 결정하는 확률 기준을 0.15 전후로 설정하는 것이 가장 Sharpe Ratio 개선에 유리하다는 의미로 해석할 수 있다. 다만 일부 경우에는 다른 값이 최적으로 선택되기도 하여 데이터 특성이나 표본의 차이에 따라 Threshold이 달라질 수 있음을 고려해야 한다.

3. 결론

3.1. 모델 성능 비교

	Naive Bayes	Support Vector Machine	Random Forest
최적 Threshold	0.1647	0.2473	0.1647
Maximized Sharpe Ratio	0.1439	0.0830	0.1844
Bootstrap 결과 요약	Mean Sharpe: 0.1424 Std Sharpe: 0.0006	Mean Sharpe: 0.0815 Std Sharpe: 0.0004	Mean Sharpe: 0.1835 Std Sharpe: 0.0006
	LightGBM	XGBoost	Multi Layer Perceptron
최적 Threshold	0.4226	0.3195	0.1493
Maximized Sharpe Ratio	0.2009	0.2016	0.1940
Bootstrap 결과 요약	Mean Sharpe: 0.1990 Std Sharpe: 0.0009	Mean Sharpe: 0.2002 Std Sharpe: 0.0006	Mean Sharpe: 0.1889 Std Sharpe: 0.0026

본 연구는 Naive Bayes, Support Vector Machine, Random Forest, LightGBM, XGBoost, Multi-Layer Perceptron 여섯 가지 머신러닝 모델의 성능을 비교했다. 성능 지표로는 모델의 단순 예측 정확도나 AUC와 같은 전통적 지표를 활용하지 않고 포트폴리오 관점에서 Sharpe Ratio가 최대화되는 최적의 Threshold를 탐색했다. 구체적인 절차는 다음과 같다. 각 모델이 산출한 확률값을 Threshold를 0.01부터 0.99까지 변화시켜 투자 여부를 결정하고, 그 결과로부터 포트폴리오의 수익률과 표준편차를 계산한 후 Sharpe Ratio를 도출했다. 이 과정에서 가장 높은 Sharpe Ratio를 기록한 Threshold를 각 모델별로 선정했다. 그리고 이를 해당 모델의 모델별 최적 Threshold와 해당 Sharpe Ratio로 활용했다.

활용 결과 Naive Bayes와 SVM은 Sharpe Ratio는 다소 낮은 수준에 머물렀다. 값은 각각 0.1439과 0.0830였다. Random Forest는 0.1844로 개선되었으나 LightGBM이나 XGBoost의 성능에는 미치지 못했다. MLP 역시 또한 0.1940의 Sharpe Ratio를 기록하며 일정 수준 이상의 결과를 보였으나 LightGBM과 XGBoost를 넘어서지는 않았다. LightGBM과 XGBoost는 각각 0.2009, 0.2016으로 다른 모델을 상회하는 Sharpe Ratio를 보였다. 특히 XGBoost가 LightGBM에 비해 Sharpe Ratio 평균은 높고 분산은 낮아 최종적으로 가장 우수한 모델로 선정됐다. 이때 산출된 최적 Threshold는 0.3195이었고 해당 설정에서 달성한 Sharpe Ratio는 0.2016로 확인됐다.

3.2. 결과 논의 및 시사점


최종적으로 선정된 모델은 XGBoost였다. Sharpe Ratio를 최대화하는 최적 Threshold와 하이퍼파라미터는 다음과 같다.

주요 하이퍼파라미터:

```
'n_estimators': 750,  
'max_depth': 9,  
'min_child_weight': 6,  
'learning_rate': 0.03200261824712448,  
'subsample': 0.850390175698195,  
'colsample_bytree': 0.8620185797319122,  
'gamma': 0.5577154468025745,  
'reg_alpha': 0.00023549278976042244,  
'reg_lambda': 0.0011914172620875896,  
'scale_pos_weight': 3.018427794887284
```

Threshold: 0.3195

이 조합으로 산출된 Sharpe Ratio는 0.2016이다. 흥미로운 점은 Threshold가 0.3195로 다소 높게 설정되었다는 것이다. 이는 투자 의사결정에서 일정 수준의 손실을 감수하더라도 그보다 더 큰 수익을 확보할 수 있다면 결과적으로 Sharpe Ratio가 높아질 수 있음을 보여준다. 즉, 단순히 손실을 줄이는 데 집중하기보다는 위험 대비 수익을 극대화하는 방향이 더 유리하다는 직관과 일치한다.



본 연구의 목표는 대출의 부도 여부를 예측하는 것이 아니라 포트폴리오의 Sharpe Ratio를 최대화하는 것이었다. 따라서 어떤 대출이 최종적으로는 부도로 처리되었더라도 일부 상환액 등으로 산출한 수익률이 동일 만기 국채 수익률보다 높다면 포트폴리오 차원에서는 긍정적으로 작용할 수 있다. 이러한 관점을 반영하여 모델은 부도 확률 자체보다는 대출의 수익률이 국채 수익률을 초과할 가능성을 예측하는 방향으로 설계했다. 즉, 부도 여부를 종속변수로 설정한 것이 아니라 개별 대출의 실현 내부수익률(IRR)이 동일 만기 국채 수익률을 초과하는지 여부를 종속변수로 설정했다. 따라서 SHAP value 분석 결과는 개별 feature들이 대출의 초과수익 발생 가능성에 어떠한 영향을 미치는지를 보여준다.

먼저 SHAP value가 가장 높은 feature는 대출기간(cat_term_60_months)이었다. 장기대출(60개월)은 초과수익 가능성을 저하시키는데, 이는 장기대출에서 불확실성과 변동성이 확대되기 때문으로 해석된다. 반대로 단기대출(36개월)은 대출의 안정성을 높이고 결과적으로 Sharpe ratio 개선에 긍정적으로 작용했다.

대출 금액(num_loan_amnt)과 부채소득비율(num_dti)은 초과수익 가능성을 저해하는 변수로 나타났다. 대출 신청금액이 적고 DTI가 낮은 대출 신청건일수록 초과 수익 가능성이 높아져 Sharpe Ratio이 개선되는 것으로 보인다. 반면 신용점수(num_avg_fico)와 연소득(num_annual_inc)은 높은 값일수록 초과수익 달성 가능성을 유의하게 높였다,

종합하면 SHAP value 분석 결과는 “단기·소액·低부채”의 특성을 가진 대출이 초과 수익 가능성이 높고 결과적으로 Sharpe ratio 개선에 기여함을 시사한다. 이는 단순한 부도 예측이 아니라 위험 대비 수익(Sharpe ratio)의 극대화라는 투자 의사결정 목표와 직접적으로 연결되는 해석을 가능하게 한다.

3.3. 한계점과 향후 과제

3.3.1. Sharpe Ratio의 절대적 수준 개선

모형을 통해 얻은 Sharpe Ratio 최댓값은 0.2016이었다. 반면 모형이 종속변수를 완벽히 예측한다고 가정했을 때 산출되는 값은 1.3093이었다. 실제 결과와 이상적 값 사이에는 상당한 차이가 있었다. 이는 중요한 변수들을 충분히 활용하지 못했고 파생변수 설계에도 한계가 있었기 때문으로 파악된다. 예컨대 직업(emp_title) 변수를 활용하지 못했는데, 고유값이 약 40만개로 다양하여 시간 관계상 모델 학습에 활용하지 않기로 결정했다. grade, subgrade와 같은 변수는 모형에 포함할 수 있는지 여부가 모호하여 보수적으로 배제했는데, 이 역시 Sharpe Ratio 개선에 한계를 가져온 요인으로 판단된다.

다음으로 효과적인 파생 변수를 생성하지 못하였다. 일부 변수에 대해 대출신청자의 신용과 어떠한 관계가 있는지 심층적 이해가 부족한 부분이 있었다. 모델의 예측에 도움이 될 것이라 생각되어 몇 개의 파생 변수를 생성했으나 오히려 모델의 성능이 저하되어 최종적으로는 파생 변수를 폐기하기로 결정했다. 대출 심사 과정에 대한 지식이 추가된다면 보다 섬세하게 데이터를 전처리 및 가공하여 모델의 성능 향상에 기여할 수 있을 것으로 예상된다.

마지막으로 데이터의 불균형으로 인해 모델이 수익률이 낮은 대출 건을 충분히 걸러내지 못한 것으로 보인다. 대부분의 대출이 국채보다 높은 수익률을 기록했으며 국채보다 낮은 수익률을 기록한 대출은 전체의 18%에 불과했다. 여러 보정 기법을 적용했음에도 불구하고 이 소수 집단을 모델이 정확히 예측하기는 어려웠다. 소수 클래스를 보다 효과적으로 학습시킬 수 있는 더 고차원의 방법론을 활용한다면 모델의 정확도가 상승하고 Sharpe Ratio 역시 베이스라인에 더 근접할 것으로 예상된다.

3.3.2. Sharpe Ratio를 학습 목적함수로의 직접 설정

본 연구의 목표는 Sharpe Ratio를 극대화하는 것이었다. 따라서 모델 학습 단계에서부터 Sharpe Ratio를 직접적인 목적함수로 설정했다면 보다 효과적인 학습이 가능했을 것으로 보인다. 이론적으로 Boosting 모델은 각 데이터 포인트별 gradient와 Hessian 근사치를 제공해야 하므로 목적함수만 정의할 수 있다면 Sharpe Ratio 최적화 역시 구현 가능하다. 그러나 Sharpe Ratio는 개별 관측치가 아닌 포트폴리오 전체의 평균 초과수익과 분산에 의존하는 전역적 지표이므로 데이터 단위로 분해 가능한 gradient/Hessian을 산출하기 어려웠다. 실제로 본 연구의 구현 과정에서도 custom objective 함수 내에서 Sharpe Ratio를 직접 반영하고자 시도했으나 sample-wise gradient와 Hessian을 정의할 수 없어 학습이 불안정해지고 수렴하지 않는 문제가 발생했다.

따라서 Sharpe Ratio를 직접 목적함수로 두는 접근은 실행에 옮기지 못했으며 [대출 건별 초과수익 발생 여부 예측 → Threshold 조정 → Sharpe ratio 극대화]라는 2단계 구조를 채택했다. 향후 연구에서 만약 Sharpe Ratio의 gradient/Hessian 근사치를 안정적으로 계산할 수 있는 방법론이 제시된다면 곧바로 Sharpe Ratio를 극대화하는 1단계 학습 구조가 가능해져 연구 목적에 보다 충실한 모형 설계가 가능할 것으로 생각된다.

4. 참고문헌

Sharpe, W. F. (1994). *The Sharpe ratio*. *Journal of Portfolio Management*, 21(1), 49–58.
<https://web.stanford.edu/~wfs Sharpe/art/sr/sr.htm>

Bhatnagar, P., Chow, N., & Lai, M. (n.d.). *Demystifying the workings of Lending Club* [CS229 course project]. Stanford University.

Chang, S., Kim, S. D.-O., & Kondo, G. (2015). *Predicting Default Risk of Lending Club* [CS229 course project]. Stanford University.

Gutierrez, A., & Mathieson, D. (n.d.). *Optimizing investment strategy in peer to peer lending* [CS229 final report]. Stanford University.

Tsai, K., Ramiah, S., & Singh, S. (2014). *Peer Lending Risk Predictor* [CS229 course project]. Stanford University.